МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ

НОВОСИБИРСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ

Факультет информационных технологий

Кафедра параллельных вычислений

ОТЧЕТ

О ВЫПОЛНЕНИИ ПРАКТИЧЕСКОЙ РАБОТЫ

«Измерение степени ассоциативности кэш-памяти»

студента 2 курса, группы 21206

Балашова Вячеслава Вадимовича

Направление 09.03.01 – «Информатика и вычислительная техника»

Преподаватель:
Кандидат технических наук
А. Ю. Власенко

Новосибирск 2022

Содержание

Цель

Экспериментальное определение степени ассоциативности кэш-памяти.

Задание

1) Написать программу, выполняющую обход памяти в соответствии с заданием.

2) Измерить среднее время доступа к одному элементу массива (в тактах процессора) для разного числа фрагментов: от 1 до 32. Построить график зависимости времени от числа фрагментов.

3) По полученному графику определить степень ассоциативности кэш-памяти, сравнить с реальными характеристиками исследуемого процессора.

4) Составить отчет по практической работе.

Описание работы

Ход выполнения работы:

1. Был создан файл MulMatrices.h (См. Приложение 1), содержащий в себе две функции: зануление матрицы и перемножение матриц. Обе функции были взяты из практики про векторизацию и слегка изменены (добавлен еще один аргумент – size – размер матрицы).

2. На основе размеров кэш-памяти процессора был выбран шаг (offset) = 16 МБ. Данное число кратно размеру кэш-памяти каждого уровня

3. Была написана программа на языке программирования C++, выполняющая обход массива, заполненного с целью получения пробуксовки кэш-памяти (см. Приложение 2). Обходы формировались в зависимости от количества фрагментов (0 <n <101), количества элементов в этих фрагментах:

   a. i <n – все элементы фрагмента переходят в соответствующие элементы следующего фрагмента.
   b. i =n – все элементы фрагмента переходят в соответствующие элементы первого фрагмента, но с циклическим сдвигом в 1.

4. После «прогрева» процессора с помощью перемножения матриц, для каждого количества фрагментов замеряется среднее время обращения к одному элементу массива. Данный замер делается 6 раз, и из всех этих замеров берется минимальное по времени значение для каждого числа фрагментов.

5. Программа компилировалась на уровне оптимизации O1, поэтому в программе присутствуют операции, не сильно влияющие на производительность и препятствующие удалению внутреннего цикла, осуществляющего обход.

6. На основе полученных данных был построен график зависимости времени обращения к элементу в зависимости от количества фрагментов.

7. На графике видны замедления. Количество фрагментов, на которых происходят замедления, соответствуют степени ассоциативности кэш-памяти соответствующих уровней.

8. Была определена ассоциативность кэш-памяти разных уровней с помощью утилиты CPU-Z, отображающей характеристики процессора. Полученные результаты были сравнены.

Рис. 1. Вывод программы CPU-Z

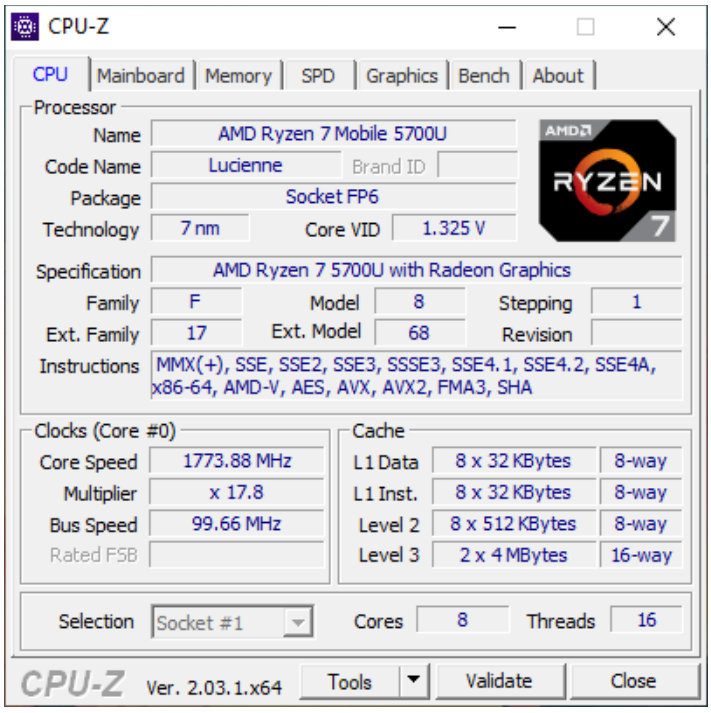

Заключение

В ходе выполнения лабораторной работы были экспериментальным методом получены степень ассоциативности кэш-памяти процессора.

С помощью анализа графика были получены значения:

1) 8 – степень ассоциативности кэш-памяти первого и второго уровней.
2) 32 – степень ассоциативности кэш-памяти третьего уровня.

С помощью утилиты CPU-Z были получены значения:

1) 8 – степень ассоциативности кэш-памяти первого и второго уровней.
2) 16 – степень ассоциативности кэш-памяти третьего уровня.

Для разных способов определения ассоциативности кэш-памяти процессора Ryzen 7 5700U были получены одинаковые значения степени ассоциативности кэш-памяти первого и второго уровней, и разные значения для степени ассоциативности кэш-памяти третьего уровня: 16 против 32.

Такой разброс получился из-за более сложного устройства кэш-памяти третьего уровня.

Приложение 1. Исходный код файла MulMatrices.h.

```
#pragma once
#include <x86intrin.h>

inline void AVX2_FillZero(float * Matrix, const size_t size)
{
   auto reg0 = _mm256_setzero_ps();
   for (auto i = Matrix; i < Matrix + size * size; i += 8)
   {
      _mm256_store_ps(i, reg0);
   }
}

inline void AVX2_MulMatrices(const float * A, const float * B, float * Res, const size_t size)
{
   AVX2_FillZero(Res, size);
   for (int i = 0; i < size; i++)
   {
      for (int k = 0; k < size; k++)
      {
         float buf[8];
         std::fill(buf, buf + 8, A[i * size + k]);
         auto reg0 = _mm256_load_ps(buf);
         for (int j = 0; j < size; j+=8)
         {
            auto reg1 = _mm256_load_ps(B + (k * size) + j);
            auto reg2 = _mm256_load_ps(Res + (i * size) + j);
            reg1 = _mm256_mul_ps(reg0, reg1);
            reg2 = _mm256_add_ps(reg2, reg1);
            _mm256_store_ps(Res + (i * size) + j, reg2);
         }
      }
   }
}
```

Приложение 2. Исходный код программы, вычисляющей время обращения к памяти.

```
#include <iostream>
#include <x86intrin.h>

#include "MulMatrices.h"

constexpr size_t LEVEL1_BANK_SIZE = 32  * 1024 / 8;
constexpr size_t LEVEL2_BANK_SIZE = 512 * 1024 / 8;
constexpr size_t LEVEL3_BANK_SIZE = 4 * 1024 * 1024 / 16;
constexpr size_t CACHE_LINE_SIZE = 64;
constexpr size_t OFFSET = 16 * 1024 * 1024;
constexpr size_t MAX_NUM_OF_FRAGMENTS = 100;
constexpr size_t SIZE_T_OFFSET = OFFSET / sizeof(size_t);
constexpr size_t NUM_OF_ITERATIONS = 10;
constexpr size_t SIZE_OF_CHECKING_ARRAY = 64;

static size_t buf = 0;

inline void FillArray(size_t * array, size_t size)
{
   for (size_t i = 0; i < size - SIZE_T_OFFSET; i += SIZE_T_OFFSET)
   {
      for (size_t j = 0; j < SIZE_OF_CHECKING_ARRAY; j++)
      {
         array[i + j] = i + j + SIZE_T_OFFSET;
      }
   }
   for (size_t j = 0; j < SIZE_OF_CHECKING_ARRAY; j++)
   {
      array[size - SIZE_T_OFFSET + j] = (j + 1) % SIZE_OF_CHECKING_ARRAY;
   }
}
int main()
{
   std::cerr << sizeof(size_t) << std::endl;
   auto * matrix1 = new float[1024 * 1024];
   auto * matrix2 = new float[1024 * 1024];
   auto * matrix3 = new float[1024 * 1024];
   for (size_t i = 0; i < 10; i++)
   {
      AVX2_MulMatrices(matrix1, matrix2, matrix3, 1024);
   }
   std::cerr << matrix3[0];

   auto * array = new size_t[MAX_NUM_OF_FRAGMENTS * SIZE_T_OFFSET];


   for (size_t i = 1; i <= MAX_NUM_OF_FRAGMENTS; i++)
   {
```

```
        FillArray(array, i * SIZE_T_OFFSET);

        long double result = UINT64_MAX;

        for (size_t j = 0; j < 6; j++)
        {
            size_t k = 0, counter = 0;
            size_t start = __rdtsc();
            while (counter < NUM_OF_ITERATIONS)
            {
                k = array[k];
                counter += !k;
            }
            size_t end = __rdtsc();
            buf = counter / i;
            result = std::min(result, static_cast <long double> (end - start) /
            (static_cast<long double> (SIZE_OF_CHECKING_ARRAY) * i *
            NUM_OF_ITERATIONS));
            std::cerr << buf;
        }
        std::cout << i << "; " << result << std::endl;
    }
    std::cerr << std::endl;



    delete[] array;

    delete[] matrix1;
    delete[] matrix2;
    delete[] matrix3;
    return 0;
}
```